



ÉCOLE CENTRALE CASABLANCA

Analyse Financière et Clustering des Entreprises

Réalisé par :

OUZAHRA Hamza
TERRAF Ahmed
TOUILE Samia
ELHATHOUT Mohammed
JADLAOUI Marwen

11 avril 2025

Table des matières

1	Introduction	2
2	Présentation des données	2
3	Nettoyage et préparation des données	3
3.1	Chargement du dataset brut	3
3.2	Normalisation des noms de colonnes	3
3.3	Suppression des doublons	3
3.4	Nettoyage des colonnes numériques	3
3.5	Nettoyage des colonnes de texte	4
3.6	Conversion de la variable date	4
3.7	Standardisation des variables catégorielles	4
3.8	Remplissage des valeurs manquantes dans les colonnes numériques	4
3.9	Visualisation et sauvegarde	4
4	Analyse exploratoire (EDA)	4
4.1	Chargement et aperçu général du dataset	5
4.2	Analyse des variables catégorielles	5
4.3	Analyse des variables numériques	7
4.4	Profit moyen par segment	12
4.5	Ventes totales par pays (Top 5)	12
4.6	6. Évolution des ventes et des profits dans le temps	13
4.7	7. Relations entre variables (Scatter plots)	14
4.8	8. Distribution du profit par segment (Boxplot)	15
4.9	9. Matrice de corrélation	16
4.10	10. Répartition par segment (Camembert)	16
4.11	Analyses complémentaires	18
4.12	Analyse des nouveaux ratios financiers	22
5	Clustering et méthodes employées	25
5.1	Création des ratios financiers et préparation des données	26
5.2	Standardisation et Réduction de dimension (PCA)	26
5.3	Détermination du nombre optimal de clusters - Méthode du coude (Elbow Method)	26
5.4	Application de l'algorithme K-Means et visualisation des clusters	27
5.5	Analyse des clusters	28
6	Analyse et interprétation économique	28
6.1	Discussion des résultats	28
6.2	Facteurs financiers explicatifs	29
6.3	Recommandations stratégiques	29
6.4	Conclusion de l'analyse économique	29
7	Conclusion et perspectives	29

1 Introduction

Dans un contexte économique de plus en plus compétitif, la capacité à analyser efficacement les données financières est devenue essentielle pour guider les décisions stratégiques des entreprises. L’objectif de ce projet est de mener une étude approfondie d’un jeu de données financiers d’entreprises, en appliquant des techniques de nettoyage, d’analyse exploratoire et de classification automatique.

Notre démarche repose sur plusieurs étapes clés : le prétraitement rigoureux des données pour garantir leur qualité, l’analyse exploratoire afin d’en dégager des tendances et relations significatives, puis l’utilisation de l’algorithme K-Means combiné à une réduction de dimension (PCA) pour identifier des groupes d’entreprises partageant des caractéristiques financières similaires.

Ce rapport s’articule autour des étapes suivantes :

- Une présentation du dataset et des variables analysées,
- Les techniques de nettoyage et de transformation appliquées,
- Une analyse exploratoire illustrée par des visualisations pertinentes,
- L’implémentation d’un modèle de clustering pour identifier des profils d’entreprises,
- Une discussion des résultats et des recommandations basées sur les insights dégagés.

Ce travail met en avant l’importance des outils d’analyse de données pour la compréhension des dynamiques économiques au sein d’un portefeuille d’entreprises, et offre des perspectives pour des analyses futures plus poussées.

Dans cette section, nous expliquons le contexte de l’analyse financière, les objectifs principaux et la structure du rapport.

2 Présentation des données

Le jeu de données utilisé dans cette étude provient d’un fichier intitulé `Financials.csv`, contenant des informations financières détaillées sur plusieurs produits commercialisés dans différents pays, segments de marché et bandes de remise (*discount bands*). Chaque ligne du dataset représente un enregistrement unique correspondant à une combinaison spécifique de produit, période et localisation géographique.

Le dataset comporte plusieurs colonnes, que l’on peut regrouper en deux grandes catégories :

- **Variables catégorielles :**
 - `product` : nom du produit,
 - `segment` : segment de marché (par exemple, Gouvernemental, PME, etc.),
 - `country` : pays dans lequel le produit est commercialisé,
 - `discount_band` : niveau de remise appliqué (faible, moyen, élevé),
 - `year` et `month_number` : date de la vente.
- **Variables numériques :**
 - `units_sold` : nombre d’unités vendues,
 - `manufacturing_price` : prix de fabrication,
 - `sale_price` : prix de vente unitaire,
 - `gross_sales` : chiffre d’affaires brut,
 - `discounts` : remises appliquées,
 - `sales` : chiffre d’affaires net (après remise),
 - `cogs` : coût des marchandises vendues,
 - `profit` : bénéfice généré.

Le fichier contient environ **1 850 lignes** et **14 colonnes**, offrant une base solide pour réaliser une analyse complète. Les données couvrent plusieurs années d'activité et permettent ainsi d'étudier les évolutions temporelles ainsi que les différences de performance selon les segments et les pays.

Ce jeu de données constitue une base pertinente pour explorer les comportements de vente, mesurer la rentabilité et identifier des typologies d'entreprises ou de produits à travers des techniques de clustering.

3 Nettoyage et préparation des données

L'objectif de cette étape est de préparer le jeu de données pour une analyse fiable et pertinente. Pour ce faire, nous avons appliqué un ensemble de transformations afin de corriger les incohérences, de standardiser les formats et d'éliminer les enregistrements indésirables. Voici les principales étapes réalisées :

3.1 Chargement du dataset brut

Action :

- Chargement du fichier `Financials.csv` provenant du dossier `data/raw/`.
- Vérification de la taille du jeu de données (nombre de lignes et de colonnes).

Interprétation : Cela permet de s'assurer que le dataset initial est complet et qu'il contient toutes les informations nécessaires pour l'analyse.

3.2 Normalisation des noms de colonnes

Action : Les noms des colonnes ont été nettoyés en supprimant les espaces superflus, en les convertissant en minuscules et en remplaçant les espaces par des underscores.

Interprétation : Cette étape améliore la cohérence et évite des erreurs lors de l'accès aux colonnes dans le code d'analyse.

3.3 Suppression des doublons

Action : Les lignes dupliquées ont été retirées du dataset.

Interprétation : Cela garantit l'unicité des enregistrements et empêche que des observations redondantes biaisent les analyses ultérieures.

3.4 Nettoyage des colonnes numériques

Action :

- Conversion des valeurs entre parenthèses en nombres négatifs.
- Suppression des symboles indésirables (par exemple, '\$' et ',').
- Transformation des chaînes vides ou contenant uniquement un tiret en valeurs manquantes (NaN), suivie de la conversion en type `float`.

Interprétation : Cette étape assure que les variables numériques sont correctement typées, facilitant les analyses statistiques et permettant d'identifier précisément les outliers.

3.5 Nettoyage des colonnes de texte

Action :

- Suppression des espaces superflus,
- Uniformisation en minuscules.

Interprétation : L'uniformisation du texte évite les incohérences (par exemple, "Low" vs "low") et simplifie l'analyse des variables catégorielles.

3.6 Conversion de la variable date

Action : Si présente, la colonne `date` a été convertie en format `datetime`.

Interprétation : La conversion du format de date permet d'exploiter la dimension temporelle du dataset pour des analyses ultérieures (tendances, saisonnalité, etc.).

3.7 Standardisation des variables catégorielles

Action : Certaines variables telles que `discount_band` ont été uniformisées pour éliminer les variations de casse et d'espaces.

Interprétation : Cela garantit que les valeurs sont cohérentes et facilite leur traitement dans les analyses et la modélisation.

3.8 Remplissage des valeurs manquantes dans les colonnes numériques

Action : Les valeurs manquantes identifiées dans les colonnes numériques ont été remplies avec la médiane de chaque colonne.

Interprétation : Le choix de la médiane permet de minimiser l'impact des valeurs aberrantes et de maintenir une distribution représentative des données.

3.9 Visualisation et sauvegarde

Action : Un boxplot de la variable `sale_price` a été généré pour vérifier visuellement la distribution et la présence éventuelle d'outliers. Ensuite, le dataset nettoyé a été sauvegardé sous le nom `Financials_cleaned.csv` dans le dossier `data/processed/`.

Interprétation : Cette étape finale permet de confirmer que le prétraitement a abouti à un jeu de données cohérent et de qualité, prêt pour les analyses exploratoires et les modèles prédictifs ultérieurs.

Conclusion de la section :

Le processus de nettoyage a permis d'obtenir un dataset homogène, exempt de doublons et d'incohérences, et dans lequel les variables sont correctement typées et standardisées. Ce jeu de données nettoyé constitue une base fiable pour réaliser une analyse exploratoire poussée et pour entraîner des modèles de clustering ou de prédiction.

4 Analyse exploratoire (EDA)

L'analyse exploratoire des données (EDA) a pour but de comprendre la structure générale du dataset, d'identifier les tendances, les relations entre variables, ainsi que les éventuelles anomalies. Voici les étapes réalisées :

4.1 Chargement et aperçu général du dataset

Action :

- Chargement du dataset nettoyé `Financials_cleaned.csv`,
- Vérification du nombre de lignes et colonnes.

Interprétation : Cela permet de s'assurer que le jeu de données est bien préparé et utilisable, sans erreurs critiques.

4.2 Analyse des variables catégorielles

Dans cette sous-section, nous étudions les variables qualitatives permettant d'identifier les cibles commerciales et la segmentation du marché. Pour chaque variable, le diagramme correspondant est affiché suivi de son interprétation.

Distribution des segments




FIGURE 1 – Distribution des segments.

Interprétation : Le graphique montre que le segment **Government** est largement dominant (environ 300 observations). Cela suggère que l'activité de l'entreprise se concentre fortement sur le secteur public, orientant ainsi les stratégies commerciales et marketing vers ce domaine.

Distribution par pays




FIGURE 2 – Répartition géographique des ventes par pays.

Interprétation : La répartition montre une couverture internationale équilibrée entre plusieurs pays (par exemple, Canada, France, Allemagne, Mexique, USA), indiquant une présence commerciale stable et diversifiée sur ces marchés.

Distribution des produits




FIGURE 3 – Distribution des produits.

Interprétation : Le diagramme en barres révèle que le produit **Paseo** se démarque avec des ventes bien supérieures aux autres, ce qui indique une forte popularité ou un avantage concurrentiel sur le marché.

Distribution des niveaux de remise (discount band)




FIGURE 4 – Distribution des niveaux de remise.

Interprétation : Les niveaux de remise les plus fréquents sont identifiés comme étant **high** et **medium**. Ceci suggère que la politique commerciale repose fortement sur l'utilisation de remises pour stimuler les ventes, visant à favoriser la compétitivité ou à attirer des segments spécifiques.

Cette analyse des variables qualitatives permet de mieux cerner les segments cibles, les préférences produits et les politiques de prix de l'entreprise. Elle constitue un socle fondamental pour guider les stratégies de segmentation et d'optimisation commerciale.

4.3 Analyse des variables numériques

Les variables numériques étudiées sont : **units_sold**, **manufacturing_price**, **sale_price**, **gross_sales**, **discounts**, **sales**, **cogs** et **profit**. Pour visualiser leur distribution, nous avons généré plusieurs histogrammes, dont voici le détail.

Histogramme des unités vendues




FIGURE 5 – Distribution des unités vendues.

Interprétation : Ce graphique montre que la distribution des `units_sold` est asymétrique, avec la majorité des valeurs concentrées dans les faibles à moyennes quantités et la présence d'outliers indiquant que certaines entreprises ont réalisé des ventes exceptionnellement élevées.

Histogramme du prix de fabrication




FIGURE 6 – Distribution du prix de fabrication.

Interprétation : La répartition des `manufacturing_price` montre une certaine variabilité, avec une concentration des valeurs autour d'un certain seuil, mais également quelques valeurs élevées qui peuvent correspondre à des produits particulièrement coûteux à fabriquer.

Histogramme du prix de vente




FIGURE 7 – Distribution du prix de vente.

Interprétation : Le diagramme du `sale_price` révèle que la majorité des produits sont vendus à des prix modérés, mais on observe également la présence d'outliers, susceptibles de correspondre à des produits haut de gamme ou à des stratégies de prix particulières.

Histogramme du chiffre d'affaires brut




FIGURE 8 – Distribution du chiffre d'affaires brut.

Interprétation : L'histogramme du `gross_sales` met en évidence une concentration des valeurs faibles à moyennes, avec quelques entreprises affichant des chiffres d'affaires exceptionnellement élevés, suggérant des disparités en taille et en performance commerciale.

Histogramme des remises appliquées




FIGURE 9 – Distribution des remises appliquées.

Interprétation : Ce graphique indique que la plupart des remises se situent dans une plage spécifique, avec quelques valeurs extrêmes qui peuvent correspondre à des promotions intensives ou à des négociations particulières avec certains clients.

Histogramme du chiffre d'affaires net




FIGURE 10 – Distribution du chiffre d'affaires net.

Interprétation : La distribution du `sales` net ressemble globalement à celle du chiffre d'affaires brut, avec la majorité des valeurs regroupées autour de faibles à moyennes sommes, et quelques outliers qui témoignent d'une performance commerciale exceptionnelle.

Histogramme du coût des marchandises vendues (COGS)




FIGURE 11 – Distribution du coût des marchandises vendues (COGS).

Interprétation : L'histogramme du `cogs` révèle une distribution asymétrique avec la présence notable de quelques valeurs élevées, ce qui peut indiquer que certaines entreprises supportent des coûts de production très importants, influençant directement leur marge bénéficiaire.

Histogramme du profit




FIGURE 12 – Distribution du profit.

Interprétation : La distribution du `profit` est fortement asymétrique, avec la majorité des entreprises générant des profits relativement faibles, tandis que quelques valeurs extrêmes (positives ou négatives) révèlent des performances exceptionnelles ou des pertes.

importantes. Cette disparité souligne la variabilité des performances financières au sein du secteur.

4.4 Profit moyen par segment

Méthode : Diagramme en barres du profit moyen par segment.




FIGURE 13 – Diagramme en barres du profit moyen par segment.

Interprétation : Ce graphique permet de détecter les segments les plus rentables. Les segments affichant un profit moyen élevé indiquent une bonne gestion des coûts et une stratégie de prix efficace, tandis que ceux avec un profit moyen faible suggèrent des points à améliorer pour optimiser la rentabilité. Ces insights orientent les décisions stratégiques en identifiant clairement les segments à fort potentiel.

4.5 Ventes totales par pays (Top 5)

Méthode : Diagramme en barres.




FIGURE 14 – Top 5 des pays par chiffre d'affaires net.

Interprétation : Le graphique met en évidence les 5 pays générant le plus grand chiffre d'affaires net. D'après l'image, l'USA apparaît en tête du classement, suivie de l'Allemagne, du Mexique, de la France et enfin du Canada. Cela indique que l'USA est le marché le plus lucratif pour l'entreprise, ce qui suggère une forte performance commerciale sur le territoire américain. De même, l'Allemagne et le Mexique affichent des résultats significatifs, ce qui permet de concentrer les efforts commerciaux et marketing sur ces marchés clés.

4.6 6. Évolution des ventes et des profits dans le temps

Méthode : Diagrammes en barres représentant l'évolution annuelle des ventes et des profits.




FIGURE 15 – Évolution des ventes par année.




FIGURE 16 – Évolution du profit par année.

Interprétation : Entre 2013 et 2014, les ventes et les profits ont fortement augmenté. Cette croissance indique une amélioration globale des performances commerciales et opérationnelles de l'entreprise, traduisant une stratégie efficace ou une hausse de la demande sur cette période.

4.7 7. Relations entre variables (Scatter plots)

Relations explorées :

- sale_price vs units_sold,
- cogs vs profit.




FIGURE 17 – Scatter plot : sale_price vs units_sold.

Interprétation : Le scatter plot montre que l'augmentation du sale_price est globalement associée à une diminution des units_sold, ce qui illustre l'effet du prix sur

le volume des ventes. Toutefois, la dispersion des points suggère également que d'autres facteurs influencent les ventes.




FIGURE 18 – Scatter plot : `cogs` vs `profit`.

Interprétation : Ce graphique met en évidence une relation négative entre le coût des marchandises vendues (`cogs`) et le `profit` : une augmentation des coûts tend à réduire la rentabilité, confirmant l'importance du contrôle des coûts pour maintenir une bonne marge.

4.8 8. Distribution du profit par segment (Boxplot)

Méthode : Diagrammes en boîtes.




FIGURE 19 – Boxplot du profit par segment.

Interprétation : Le boxplot révèle des différences marquées dans la distribution du profit entre les segments. Certains segments présentent une grande variabilité et des valeurs extrêmes, tandis que d'autres sont relativement homogènes. Cette information est cruciale pour identifier les segments à risque ou ceux offrant les meilleures marges.

4.9 9. Matrice de corrélation

Méthode : Heatmap annotée.




FIGURE 20 – Matrice de corrélation annotée.

Interprétation : La heatmap montre des corrélations importantes entre plusieurs variables numériques. Notamment, une forte corrélation positive est observée entre **sales** et **units_sold**, tandis que la relation entre **sales** et **profit** est modérée. Ces corrélations soutiennent les hypothèses sur l'impact du volume de ventes sur la rentabilité globale.

4.10 10. Répartition par segment (Camembert)

Méthode : Diagramme circulaire.




FIGURE 21 – Répartition des entreprises par segment.

Interprétation : Le camembert met en avant la part relative de chaque segment dans l'ensemble du dataset. Il est évident que le segment **Government** domine, ce qui pourrait justifier une orientation stratégique spécifique vers ce marché. De plus, cette répartition aide à comprendre comment les ressources doivent être distribuées pour maximiser l'impact commercial.

4.11 Analyses complémentaires

A. Évolution mensuelle des ventes et profits




FIGURE 22 – Évolution mensuelle des ventes et des profits.

Interprétation : On observe des pics de ventes en octobre et décembre 2014, accompagnés d'une augmentation notable du profit. Cette dynamique reflète une saisonnalité commerciale probable, avec des périodes stratégiques (fin d'année) où la demande est plus élevée.

B. Heatmap Produit vs Segment (units sold)




FIGURE 23 – Heatmap des unités vendues selon les produits et les segments.

Interprétation : Le produit **Paseo** dans le segment **Government** affiche le plus grand nombre d'unités vendues, ce qui suggère un fort succès de ce produit sur le marché public. De même, **Velo** performe bien dans les segments **Government** et **Enterprise**, montrant une bonne adoption de ce produit.

C. Heatmap Produit vs Réduction (units sold)




FIGURE 24 – Heatmap des unités vendues selon les produits et les niveaux de réduction.

Interprétation : Le produit Paseo est particulièrement sensible aux remises : les ventes augmentent fortement avec des niveaux de réduction **high** et **medium**. Ce comportement met en évidence l'effet incitatif des promotions sur ce produit.

D. Heatmap Segment vs Réduction (profit)




FIGURE 25 – Heatmap du profit selon les segments et les niveaux de remise.

Interprétation : Le segment **Government** génère le plus de profit, en particulier avec les remises **low**. Cela suggère que ce segment reste très rentable même avec une politique de remise modérée.

E. Heatmap Produit vs Réduction (profit)




FIGURE 26 – Heatmap du profit selon les produits et les niveaux de remise.

Interprétation : Paseo génère le plus de profit, surtout avec une remise low, suivi par VTT et Velo. Cette observation peut guider les décisions commerciales en recommandant des réductions modérées pour maximiser la rentabilité.

4.12 Analyse des nouveaux ratios financiers

Afin d’approfondir l’évaluation des performances financières, nous avons complété l’EDA en calculant et en visualisant de nouveaux ratios clés. Ces ratios permettent notamment d’évaluer la rentabilité, l’endettement, la liquidité et l’efficacité d’utilisation des actifs. Les indicateurs calculés sont les suivants :

- **ROA (Return on Assets)** : rapport entre le résultat net et le total des actifs, qui mesure la rentabilité des actifs.
- **ROE (Return on Equity)** : rapport entre le résultat net et les capitaux propres, évaluant la rentabilité des fonds investis.
- **Marge nette** : rapport entre le résultat net et le chiffre d’affaires net, indiquant la part du CA transformée en profit.
- **Endettement** : rapport entre les dettes et les capitaux propres, reflétant la structure financière.
- **Liquidité** : rapport entre les actifs circulants et les passifs circulants, mesurant la capacité à couvrir les engagements à court terme.
- **Rotation des actifs** : rapport entre le chiffre d’affaires et le total des actifs, indiquant l’efficacité d’utilisation des ressources.

Chaque ratio a été visualisé à l’aide d’un histogramme, sauf dans le cas de variables quasi-constantes pour lesquelles un diagramme à barres a été utilisé.

Histogrammes des ratios financiers :




FIGURE 27 – Histogramme du ROA.




FIGURE 28 – Histogramme du ROE.




FIGURE 29 – Histogramme de la marge nette.




FIGURE 30 – Histogramme du ratio d'endettement.




FIGURE 31 – Histogramme du ratio de liquidité.




FIGURE 32 – Histogramme de la rotation des actifs.

Interprétation : Les graphiques révèlent la distribution de chaque ratio sur l'ensemble des entreprises. On observe par exemple que le ROA et le ROE restent relativement homogènes, indiquant une rentabilité modérée pour la majorité des entreprises, tandis que la marge nette présente une variabilité plus marquée. Le ratio d'endettement souligne une forte dépendance aux financements externes, et les ratios de liquidité ainsi que la rotation des actifs mettent en exergue l'efficacité opérationnelle et la capacité des entreprises à gérer leurs ressources.

5 Clustering et méthodes employées

Dans cette section, nous présentons la démarche de clustering appliquée aux données financières afin d'identifier des profils d'entreprises à partir de nouveaux ratios clés. Cette

approche permet de mieux comprendre la rentabilité, la structure financière et l'efficacité opérationnelle des entreprises.

5.1 Création des ratios financiers et préparation des données

Méthode : Afin d'approfondir l'analyse financière, nous avons enrichi notre dataset en créant de nouveaux ratios financiers. Nous avons établi les règles suivantes :

- Si la colonne `net_income` n'existe pas, nous utilisons `profit` comme résultat net.
- Le **total des actifs** est estimé comme 10 fois le chiffre d'affaires net (`sales`).
- Les **capitaux propres** (`equity`) sont fixés à 20% du total des actifs.
- Les **dettes** (`liabilities`) représentent 80% du total des actifs.
- Les **actifs circulants** et les **passifs circulants** sont estimés respectivement à 50% et 30% du total des actifs.

À partir de ces estimations, nous avons calculé les ratios suivants :

- **ROA** (Return on Assets) = $\frac{\text{net_income}}{\text{total_assets}}$,
- **ROE** (Return on Equity) = $\frac{\text{net_income}}{\text{equity}}$,
- **Marge nette** = $\frac{\text{net_income}}{\text{sales}}$,
- **Endettement** = $\frac{\text{liabilities}}{\text{equity}}$,
- **Liquidité** = $\frac{\text{current_assets}}{\text{current_liabilities}}$,
- **Rotation des actifs** = $\frac{\text{sales}}{\text{total_assets}}$.

Interprétation : Ces ratios offrent une vision globale de la performance financière : la rentabilité (ROA, ROE, marge nette), la structure financière (endettement), la capacité à faire face aux engagements à court terme (liquidité) et l'efficacité d'utilisation des actifs (rotation des actifs).

5.2 Standardisation et Réduction de dimension (PCA)

Méthode : Les ratios nouvellement calculés sont extraits et standardisés à l'aide d'un `StandardScaler`. Une Analyse en Composantes Principales (PCA) est ensuite appliquée pour réduire la dimensionnalité à deux composantes, facilitant ainsi la visualisation des clusters.

Interprétation : La PCA permet de conserver l'essentiel de la variance des données tout en les projetant dans un espace en 2D, rendant l'analyse visuelle plus intuitive.

5.3 Détermination du nombre optimal de clusters - Méthode du coude (Elbow Method)

Méthode : Nous appliquons l'algorithme K-Means sur l'espace réduit par PCA pour des valeurs de k variant de 1 à 10. En traçant l'inertie en fonction de k , nous identifions le "coude", c'est-à-dire le point où l'inertie diminue fortement puis se stabilise.




FIGURE 33 – Méthode du coude pour déterminer le nombre optimal de clusters.

Interprétation : La courbe montre une forte baisse de l’inertie entre $k = 1$ et $k = 2$, suivie d’une stabilisation pour $k > 2$. Cela suggère que la segmentation en 2 clusters capture efficacement la structure des données.

5.4 Application de l’algorithme K-Means et visualisation des clusters

Méthode : L’algorithme K-Means est appliqué avec $k = 2$ sur les données projetées par PCA. Les clusters obtenus sont ensuite visualisés sur un scatter plot, où chaque point est coloré selon son affiliation de cluster.




FIGURE 34 – Visualisation des clusters obtenus avec $k = 2$ via PCA.

Interprétation : Le scatter plot révèle deux groupes distincts. Le premier cluster

regroupe des entreprises présentant des ratios financiers indiquant une meilleure rentabilité et une gestion des coûts plus efficace, tandis que le second cluster correspond à des entreprises avec des performances financières moins favorables.

5.5 Analyse des clusters

Méthode : Nous ajoutons la variable **Cluster** au DataFrame et calculons la moyenne de chacun des ratios financiers pour chaque cluster :

```
Mean of each ratio by cluster:
```

	roa	roe	marge_nette	endettement	liquidite	rotation_actifs
Cluster						
0	0.059314	0.296569	0.593139	4.0	1.666667	0.1
1	0.017087	0.085435	0.170871	4.0	1.666667	0.1

FIGURE 35 – Moyenne de chaque ratio par cluster.

Interprétation : Les moyennes indiquent des profils distincts :

- Le **Cluster 0** affiche, par exemple, des ROA et ROE élevés ainsi qu’une marge nette forte, reflétant une meilleure rentabilité.
- Le **Cluster 1** présente des valeurs plus faibles de rentabilité et un niveau d’endettement élevé, traduisant des performances financières globalement réduites.

Conclusion de la section Clustering : L’application de K-Means basée sur les nouveaux ratios financiers, complétée par une réduction de dimension par PCA et une détermination du nombre optimal de clusters via la méthode du coude, a permis de segmenter efficacement le portefeuille d’entreprises en deux groupes distincts. Ces résultats fournissent des informations stratégiques précieuses pour orienter les décisions commerciales.

6 Analyse et interprétation économique

L’analyse exploratoire (EDA) couplée au clustering basé sur les nouveaux ratios financiers nous offre une vision détaillée de la performance et de la structure financière des entreprises. En exploitant des indicateurs tels que le ROA, le ROE, la marge nette, l’endettement, la liquidité et la rotation des actifs, nous identifions deux profils distincts qui traduisent des niveaux de rentabilité, d’efficacité et de risque financier très différents.

6.1 Discussion des résultats

Les observations principales issues de l’analyse sont les suivantes :

- **Rentabilité et efficacité :** Le **Cluster 0** se caractérise par des valeurs élevées de ROA et de ROE ainsi qu’une marge nette soutenue. Ces résultats indiquent une bonne capacité à générer des profits à partir des actifs et des capitaux propres, ainsi qu’une utilisation optimale des ressources (rotation des actifs élevée).
- **Structure financière :** Le **Cluster 1** présente un niveau d’endettement plus important et une liquidité plus faible. Ces indicateurs suggèrent une dépendance accrue aux financements externes et un risque financier plus élevé.

- **Différenciation des profils** : La segmentation basée sur ces nouveaux ratios permet de distinguer clairement les entreprises à forte performance financière de celles qui pourraient nécessiter des mesures pour optimiser leur gestion des coûts et réviser leur structure de financement.

6.2 Facteurs financiers explicatifs

Plusieurs indicateurs clés se dégagent pour expliquer la performance globale :

- Le **ROA** (Return on Assets) et le **ROE** (Return on Equity) mesurent respectivement la rentabilité par rapport aux actifs et aux capitaux propres.
- La **marge nette** exprime l'efficacité de la conversion du chiffre d'affaires en profit.
- Le ratio d'**endettement** informe sur la structure financière et le niveau de risque lié aux financements externes.
- Le ratio de **liquidité** évalue la capacité de l'entreprise à couvrir ses obligations à court terme.
- La **rotation des actifs** mesure l'efficacité d'utilisation des actifs pour générer des ventes.

6.3 Recommandations stratégiques

Sur la base de ces analyses, plusieurs pistes d'optimisation sont envisagées :

- **Optimisation de la rentabilité** : Pour les entreprises du Cluster 1, il serait judicieux d'améliorer l'efficacité opérationnelle et de revoir la politique de prix afin d'améliorer la marge nette et la rentabilité.
- **Gestion du risque financier** : Un endettement élevé incite à réévaluer la structure financière, avec un effort sur la réduction des dettes ou l'amélioration de la génération de fonds propres.
- **Amélioration de la liquidité et de l'efficacité** : Des mesures visant à optimiser la gestion des actifs, par exemple en augmentant la rotation des actifs, pourraient renforcer la capacité de l'entreprise à répondre à ses obligations à court terme.

6.4 Conclusion de l'analyse économique

En résumé, l'intégration des nouveaux ratios financiers dans l'analyse et le clustering permet de distinguer deux profils d'entreprises clairement différenciés : l'une avec une forte rentabilité et une utilisation efficace des ressources, et l'autre présentant une structure financière plus fragile avec un endettement élevé et une liquidité réduite. Ces insights offrent une base solide pour orienter les décisions stratégiques et améliorer la compétitivité des entreprises dans un environnement économique complexe.

7 Conclusion et perspectives

Dans ce rapport, nous avons présenté une démarche complète d'analyse des données financières, incluant le nettoyage, l'analyse exploratoire enrichie par l'intégration de nouveaux ratios financiers (ROA, ROE, marge nette, endettement, liquidité et rotation des actifs) et la segmentation par clustering. L'utilisation de ces indicateurs nous a permis d'obtenir une vision plus fine de la performance financière et de la structure économique des entreprises.

Résumé des points clés

- Le dataset, une fois nettoyé et enrichi avec de nouveaux ratios financiers, offre une base robuste pour l'analyse.
- L'analyse exploratoire (histogrammes, boxplots, scatter plots, heatmaps) a révélé des disparités importantes dans la rentabilité, la structure de coûts et l'efficacité de gestion des entreprises.
- Le clustering, réalisé sur la base des nouveaux ratios et après standardisation et réduction de dimension par PCA, a permis de distinguer deux profils d'entreprises distincts : un groupe affichant une forte rentabilité et une bonne gestion des coûts, et un autre groupe présentant une rentabilité plus modeste et des niveaux d'endettement plus élevés.

Limites

Malgré la richesse des résultats obtenus, cette étude présente certaines limites :

- La qualité et la représentativité des résultats dépendent fortement des hypothèses utilisées pour estimer certaines variables (par exemple, le total des actifs estimé comme 10 fois le chiffre d'affaires).
- Les méthodes d'imputation et de transformation appliquées peuvent introduire des biais qui affectent les calculs des ratios.
- L'utilisation exclusive de K-Means et de la PCA simplifie la complexité des dynamiques financières, sans capturer l'ensemble des aspects possibles.

Pistes d'améliorations et perspectives

Pour approfondir cette étude, plusieurs pistes d'amélioration peuvent être envisagées :

- **Collecte de données supplémentaires** : Obtenir un échantillon plus large et plus représentatif permettrait de valider les tendances observées.
- **Exploration d'autres algorithmes de clustering** : Tester des méthodes telles que DBSCAN, le clustering hiérarchique ou des approches supervisées pourrait offrir une vision complémentaire des profils d'entreprises.
- **Affinement des estimations des ratios** : Intégrer des données réelles pour des indicateurs comme le total des actifs, les capitaux propres ou les passifs circulants améliorerait la précision des ratios.
- **Approfondissement sectoriel** : Intégrer des variables externes (macroéconomiques, sectorielles) et segmenter plus finement les données permettraient d'obtenir des insights supplémentaires et d'identifier des leviers d'optimisation spécifique à chaque secteur.

En conclusion, cette étude démontre l'importance d'une approche analytique fine à travers l'utilisation de ratios financiers détaillés pour segmenter les entreprises. Un contrôle rigoureux des coûts, couplé à une stratégie de prix adaptée et à un ciblage précis des marchés, apparaît comme le levier principal pour renforcer la compétitivité dans un environnement économique complexe.